Soutenance Projet 7 : "Déployer un modèle dans le cloud "



Sommaire

- I. Problématique
- II. Les données
- III. Architecture Big Data
- IV. Chaîne de traitement
- V. Conclusion



I. Problématique

- Data scientist pour la société Agritech 'Fruits' qui cherche à proposer des solutions innovantes pour la récolte des fruits.
- La société souhaite dans un premier temps se faire connaître en mettant à disposition du grand public une application mobile qui permettrait aux utilisateurs de prendre en photo un fruit et d'obtenir des informations sur ce fruit.
- Cette application permettrait de sensibiliser le grand public à la biodiversité des fruits.
- Le développement de l'application mobile permettra de construire une première version de l'architecture Big Data nécessaire.

Notre mission :

- Développer dans un environnement Big Data une première chaîne de traitement des données qui comprendra un preprocessing et une étape de réduction de dimension.
- Garder en tête que l'important est de mettre en place les premières briques de traitement qui serviront lorsqu'il faudra passer à l'échelle en termes de volume de données!



I. Problématique

Démarche de travail :

- Analyse rapide des données disponibles.
- Récupérer un sample de ces données pour faire des essais.
- Mettre en place une chaîne de traitement en local sur machine virtuelle pour effectuer des premiers tests.
- Mettre en place une première architecture Big Data via les services AWS.
- > Valider notre chaîne de traitement dans cette architecture.
- Privilégier un coût faible pour démontrer la faisabilité avant un passage à l'échelle (première brique de l'architecture).
- Envisager le passage à l'échelle pour des données plus conséquentes.



II. Les données

Données disponibles via l'adresse :

- https://www.kaggle.com/datasets/moltean/fruits
- Dossier Training :
 - > 131 Fruits
 - > 500 images par fruits en moyenne
 - Pour des raisons de coût mémoire on utilise un petit échantillon de 3 fruits avec 2-4 images par fruits (9 images).



II. Les données

Les images sélectionnées :





Rappels:

- On parle de Big Data lorsque la quantité de données excède la faculté d'une machine à les stocker et les analyser en temps acceptable.
- L'idée est de distribuer les calculs entre plusieurs machines.
- Paradigme diviser pour mieux régner / MapReduce
- Infrastructure logiciel dédié :
 - Data locality, optimiser les déplacements de données
 - Scalability, adapter la puissance au besoin
 - Embracing failure, tolérant aux pannes



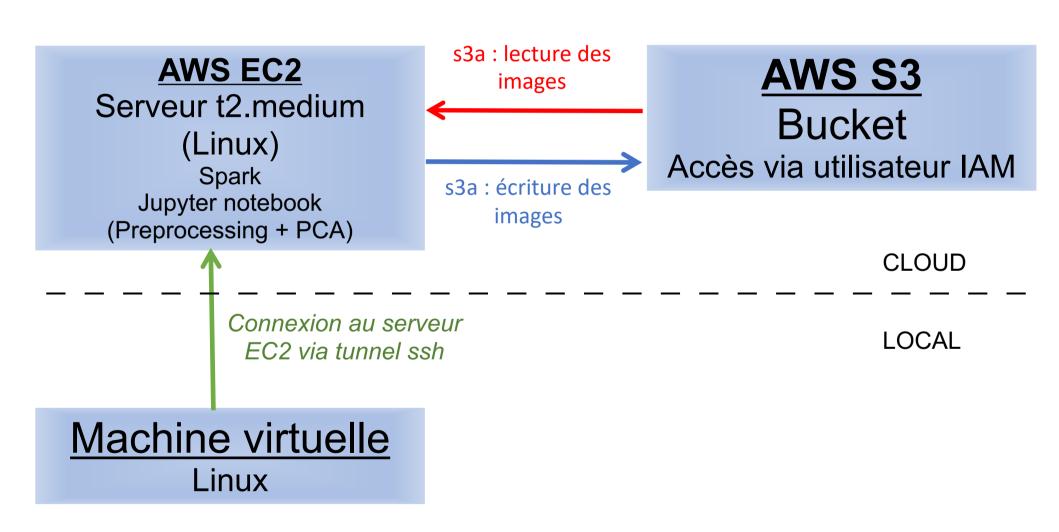
- Architecture hébergée sur Amazon Web Services (AWS) :
- Un serveur EC2 de type t2.medium (RAM 4GB)
 - Communication via ssh
 - Utilisation de Spark (via pyspark)
 - Utilisation Jupyter

Un espace de stockage S3

- Accès privés
- Utilisation d'un profile utilisateur IAM pour les accès en lecture et écriture



Schéma de l'architecture :



- Serveur EC2
 - Machine virtuelle sur le cloud
 - Configurations sous AWS :
 - Linux (Ubuntu 22.04)
 - Ouverture d'accès :
 - Port 22 pour le tunnel ssh
 - Port 8888 pour jupyter notebook (TCP)
 - Port 4040 pour SparkUI (TCP)
 - Installations via ssh:
 - 。 Java 8/11
 - Spark, spark-3.3.0-bin-hadoop3
 - 。 Jupyter (py4j)



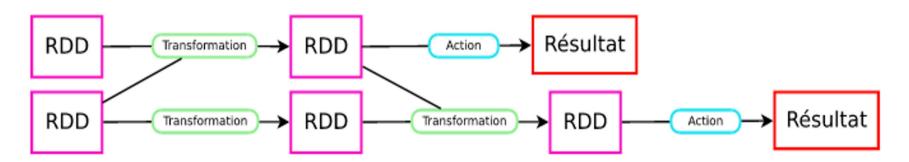
Stockage S3 :

- Espace de stockage sur le cloud
- Création d'un bucket «openclassroom-p8ceyhun»
- Contenu privé
- Création d'un profile utilisateur IAM (ID + clé secrète) avec droits administrateur pour y accéder
- Ajout du dossier sample des images via commande bash



Calcul distribué Spark :

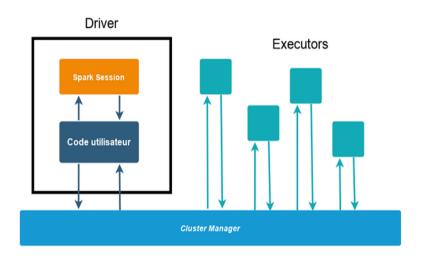
- Utilise la RAM pour gagner en temps d'exécution
- Elargit le cadre map/reduce en proposant à l'utilisateur des opérations supplémentaires pouvant être réalisées de manière distribuée
- Effectue des transformations et actions sur des RDD (Resilient Distributed Dataset)

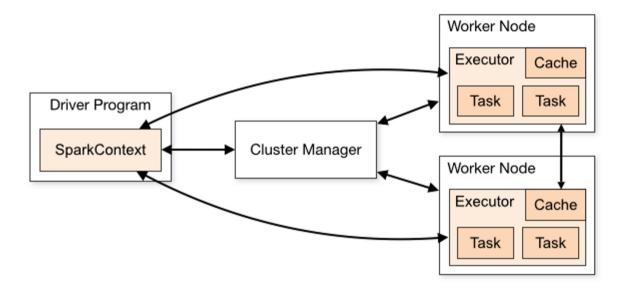


 Permet également de passer par des données structurés de type Dataframe

Calcul distribué Spark :

Utilisation de PySpark (script python) en mode standalone





- Worker = machine physique
- Executor = application qui tourne sur la machine physique
- Driver Program → Distribue les tâches sur les executors
- Cluster Manager → Instancie les différents workers

- Les étapes du traitement :
 - Lecture/chargement des images présentes sur AWS S3
 - Preprocessing (resize) pour Spark
 - Prédire avec RESNET50 model
 - Réduction de dimension des features par PCA

 Script Python via jupyter notebook (utilisation du port 8888 du serveur EC2)



1) Chargement des images du bucket S3 dans un dataframe Spark

```
In [4]: # Define S3 path
         path s3 = 's3a://openclassroom-p8-ceyhun/fruits sample'
         path s3 root = 's3a://openclassroom-p8-ceyhun'
 In [5]: df image = spark.read.format('image').load(f"{path s3}/*")
         df image.show(5)
         22/10/09 15:37:18 WARN MetricsConfig: Cannot locate configuration: tried hadoop-metrics2-s3a-
         file-system.properties, hadoop-metrics2.properties
          {s3a://openclassr...
          {s3a://openclassr...
          {s3a://openclassr...
          {s3a://openclassr...
          {s3a://openclassr...
         +----+
         Import data
In [9]:
         df image.printSchema()
         root
          -- image: struct (nullable = true)
               -- origin: string (nullable = true)
               -- height: integer (nullable = true)
                -- width: integer (nullable = true)
                -- nChannels: integer (nullable = true)
                -- mode: integer (nullable = true)
                -- data: binary (nullable = true)
In [10]: print(f"count of image = {df image.count()} length of columns = {len(df image.columns)}")
         count of image = 13 length of columns = 1
```

2) Récupération des labels et remise en forme du dataframe Spark

Converting all images in Spark

```
In [11]: image row = 7
In [12]: schema = StructType(df image.select("image.*").schema.fields + [
             StructField("data as resized array", ArrayType(IntegerType()), True),
             StructField("data as array", ArrayType(IntegerType()), True)
         1)
         def convert bgr array to rgb array(img array):
             B, G, R = img array.T
             return np.array((R, G, B)).T
         def resize img(img data, resize=True):
             mode = 'RGBA' if (img data.nChannels == 4) else 'RGB'
             img = Image.frombytes(mode=mode, data=img data.data, size=[img data.width, img data.height]
             img = img.convert('RGB') if (mode == 'RGBA') else img
             img = img.resize([224, 224], resample=Image.Resampling.BICUBIC) if (resize) else img
             arr = convert bgr array to rgb array(np.asarray(img))
             arr = arr.reshape([224*224*3]) if (resize) else arr.reshape([img data.width*img data.height
             return arr
         def resize image udf(dataframe batch iterator: Iterator[pd.DataFrame]) -> Iterator[pd.DataFrame
             for dataframe batch in dataframe batch iterator:
                 dataframe batch["data as resized array"] = dataframe batch.apply(resize img, args=(True
                 dataframe batch["data as array"] = dataframe batch.apply(resize img, args=(False,), axi
                 vield dataframe batch
         resized df = df image.select("image.*").mapInPandas(resize image udf, schema)
```

We can check if the data contains a converted and a resized image

3) Utilisation de RESNET50:

Predicting with the ResNet50 model

```
In [17]:
    def normalize_array(arr):
        return tf.keras.applications.resnet50.preprocess_input(arr.reshape([224,224,3]))

@pandas_udf(ArrayType(FloatType()))
def predict_batch_udf(iterator: Iterator[pd.Series]) -> Iterator[pd.Series]:
        model = ResNet50(weights=None)
        model.set_weights(bc_model_weights.value)
        for input_array in iterator:
            normalized_input = np.stack(input_array.map(normalize_array))
            preds = model.predict(normalized_input)
            yield pd.Series(list(preds))

predicted_df = resized_df.withColumn("predictions", predict_batch_udf("data_as_resized_array"))
```

4) Utilisation de la PCA de « pyspark.ml.feature » :

```
def pca transformation(df, n components=2, col image='image'):
   Applique un algorithme de PCA sur l'ensemble des images pour réduire la dimension de chaque
   du jeu de données.
   Paramètres:
   df(pyspark dataFrame): contient une colonne avec les données images
   n components(int): nombre de dimensions à conserver
   col image(string): nom de la colonne où récupérer les données images
    # Initilisation du temps de calcul
   start time = time.time()
    # Les données images sont converties au format vecteur dense
    #ImageSchema.imageFields
    img2vec = F.udf(lambda x : Vectors.dense(x), VectorUDT())
   df = df.withColumn("data as vector", img2vec("data as resized array"))
    standardizer = StandardScaler(withMean=True, withStd=True, inputCol="data as vector", outpu
   model std = standardizer.fit(df)
   df = model std.transform(df)
    # Entrainement de l'algorithme
   pca = PCA(k=n components, inputCol='data as vector', outputCol='pcaFeatures')
   model pca = pca.fit(df)
   # Transformation des images sur les k premières composantes
   df = model pca.transform(df)
   df = df.filter(df.pcaFeatures.isNotNull())
   print(model pca.explainedVariance)
    # Affiche le temps de calcul
   print("Temps d'execution {:.2f} secondes".format(time.time() - start time))
   return df
```

5) Enregistrement des résultats dans le bucket S3

Save Files as Parquet

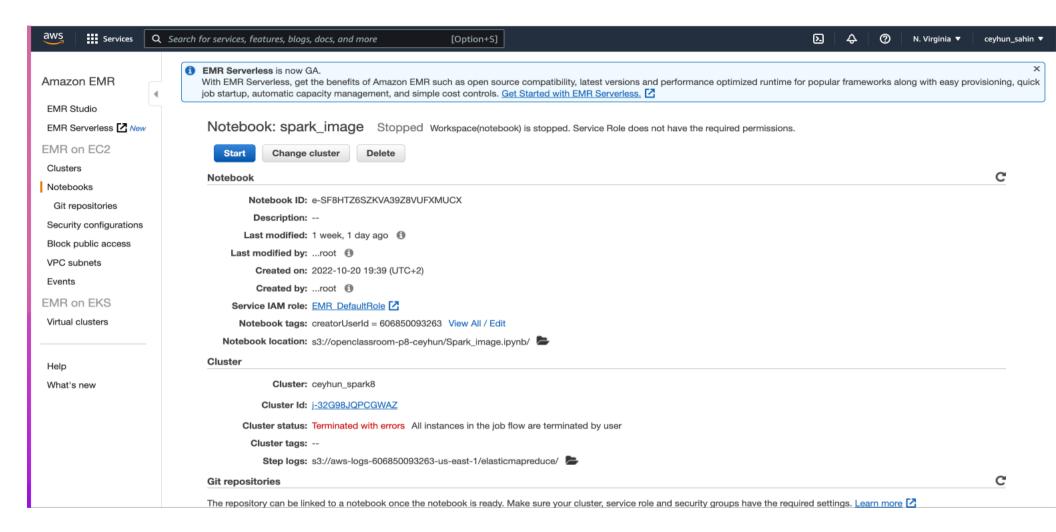
```
In [32]: result df = df.select('img path s3', 'pcaFeatures', 'label')
         result df.show()
         22/10/09 15:42:39 WARN DAGScheduler: Broadcasting large task binary with size 2.4 MiB
         [Stage 34:>
                                                                              (0 + 1) / 11
                   img path s3
                                        pcaFeatures
          openclassroom-p8-... [-36292.775883125...]
                                                         cabbage white 1
          openclassroom-p8-... [-33814.861621121...]
                                                         cabbage white 1
          openclassroom-p8-... [-34564.791956497...]
                                                         cabbage white 1
          openclassroom-p8-... [-11680.891318570...]
                                                              cucumber 1
          openclassroom-p8-... [-10799.869759969...]
                                                              cucumber 1
          openclassroom-p8-... [-38651.840423738... apple granny smith 1
          openclassroom-p8-... [-40391.651082526... apple granny smith 1
          openclassroom-p8-... [-39437.741593447... apple granny smith 1
          openclassroom-p8-... [-36272.882319034... apple granny smith 1
          openclassroom-p8-... [-12509.175459769...]
                                                           apple rotten 1
          openclassroom-p8-... [-8275.7465326340...]
                                                           apple rotten 1
          openclassroom-p8-... [-11691.208398820...]
                                                          apple rotten 1
          openclassroom-p8-... [-9649.1109840233...]
                                                          apple rotten 1
```

V. Conclusion

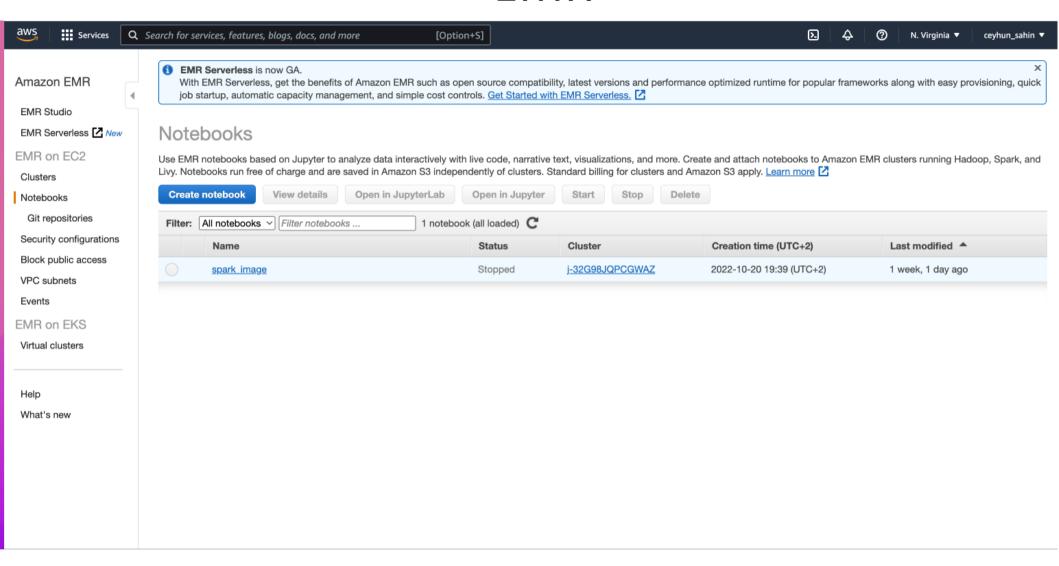
- Mise en place d'une première architecture Big Data.
- Développement d'une chaîne de traitement via pyspark fonctionnelle sur cette architecture.
- Recommendations pour un passage à l'échelle :
- Utiliser les outils de « cost managment » de AWS pour gérer les coût de l'infrastructure.
- Peut être voir pour améliorer la chaîne de traitement et passer par un preprocessing plus poussé (transfer learning)?

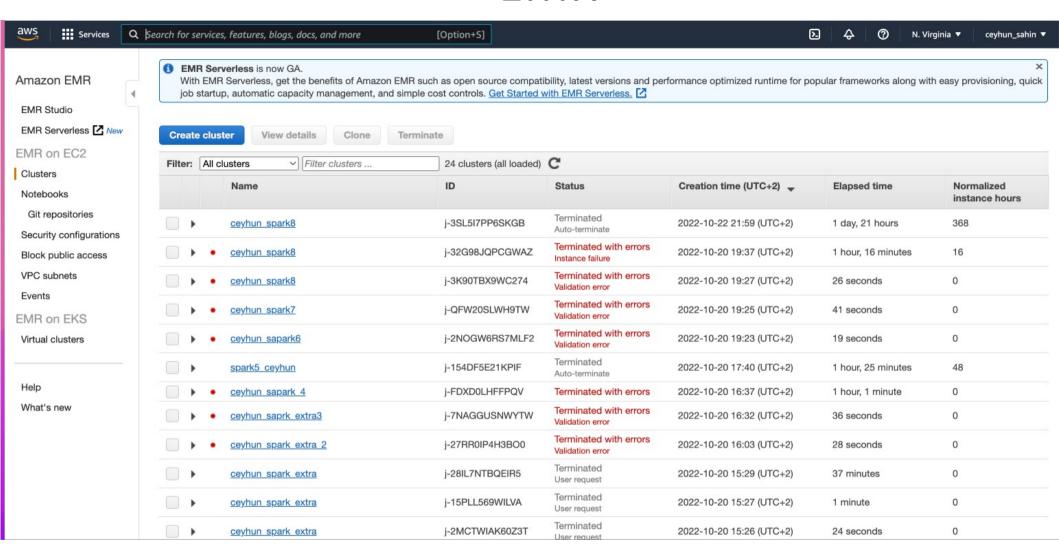


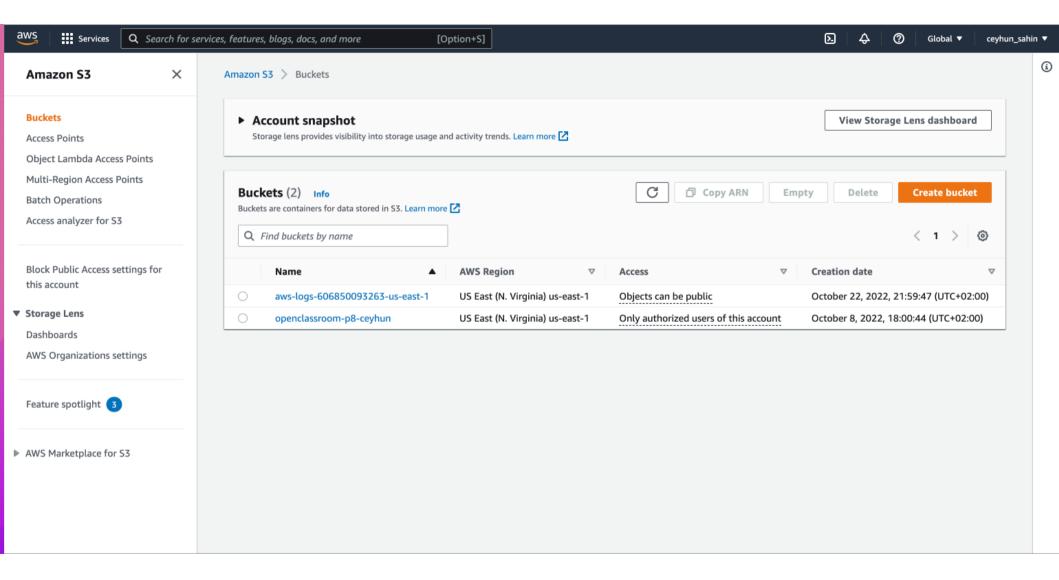
Merci pour votre attention! Questions?

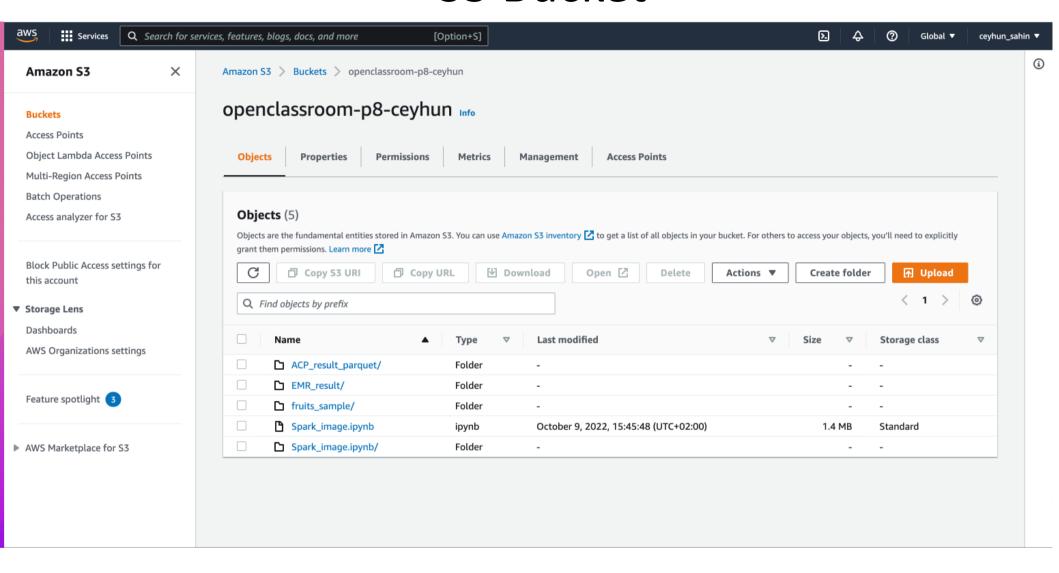


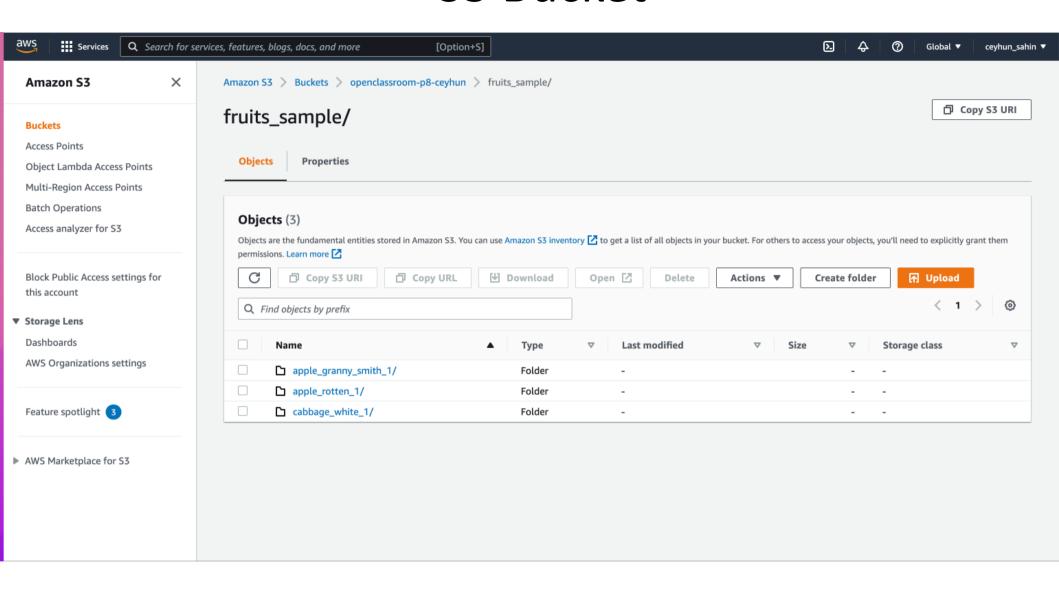
EMR

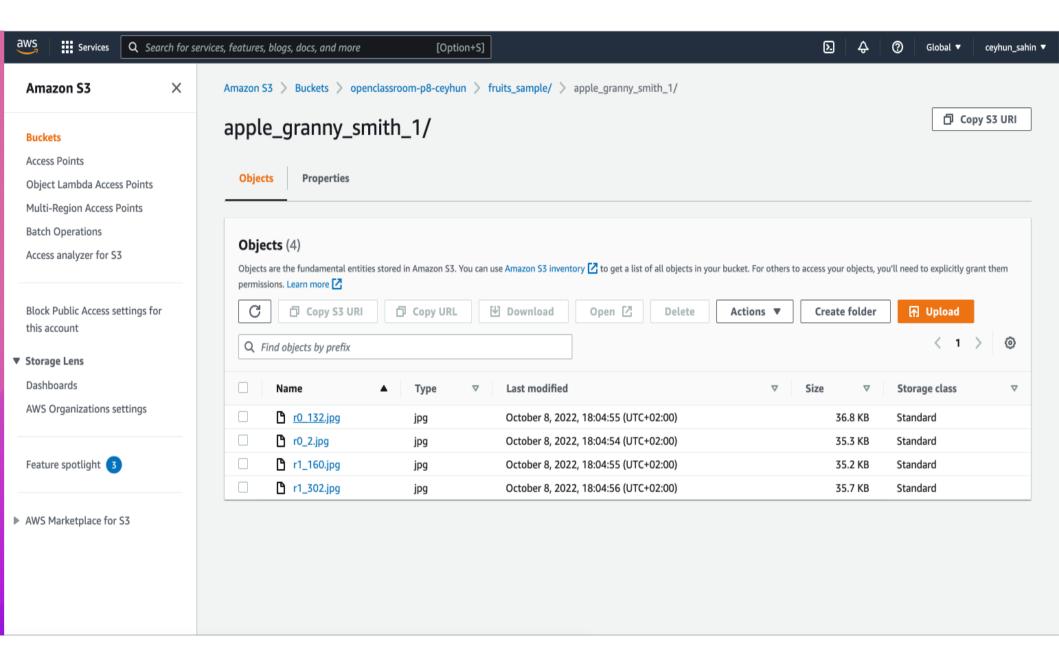












EC2

